<pre>In [1]: import pandas as pd import numpy as np import matplotlib.pyplot as plt from sklearn import preprocessing import seaborn as sns from sklearn.duster import PCA from sklearn.cluster import KMeans from sklearn.preprocessing import StandardScaler</pre> In [2]: data = pd.read_csv("Mall_Customers.csv", sep=",") data	
Out[2]: CustomerID Gender Age Annual Income (k\$) Spending Score (1-100) 0 1 Male 19 15 39 1 2 Male 21 15 81 2 3 Female 20 16 6 3 4 Female 23 16 77 4 5 Female 31 17 40	
195 196 Female 35 120 79 196 197 Female 45 126 28 197 198 Male 32 126 74 198 199 Male 32 137 18 199 200 Male 30 137 83 200 rows × 5 columns	
Stworzyć histogramy dla wieku, rocznego dochodu i oceny wydawania. In [3]: plt.hist(data["Age"], facecolor='blue', alpha=0.5) plt.title("Age Histogram") plt.xlabel('Age in Years') plt.ylabel('Amount of People') plt.show()	
Age Histogram 35 30 25 25 30 51 51 51 51	
In [7]: plt.hist(data["Annual Income (k\$)"], facecolor='blue', alpha=0.5) plt.title("Annual Income Histogram") plt.xlabel('Income in k \$')	
plt.ylabel('Amount of People') plt.show() Annual Income Histogram 35 - 30 -	
25 - 20 - 20 - 40 - 60 - 80 - 100 - 120 - 140 Income in k \$	
In [8]: plt.hist(data["Spending Score (1-100)"], facecolor='blue', alpha=0.5) plt.title("Spending Score Histogram") plt.xlabel('Score from 0 to 100') plt.ylabel('Amount of People') plt.show() Spending Score Histogram 35	
30 - Body 25 - Body 20 - B	
Porównać na wykresie liczbę kobiet i mężczyzn. In [4]: amount_of_women = len(list(filter(lambda x: x == "Male", data["Gender"]))) amount_of_men = len(list(filter(lambda x: x == "Female", data["Gender"]))) amount = len(data["Gender"]) # dwa razy sprawdzam ze wzgledu ze moze byc cos innego niz Male lub Female	
<pre>objects = ('Men' + str(amount_of_men), 'Women' + str(amount_of_women)) y_pos = np.arange(len(objects)) performance = [amount_of_men/amount, amount_of_women/amount] plt.barh(y_pos, performance, align='center', alpha=0.5) plt.yticks(y_pos, objects) plt.xlabel('Amount') plt.title('Amount of Women and Men') plt.show()</pre>	
Amount of Women and Men Women 88 - Men 112 -	
Przedstawić na wykresie zależności pomiędzy wiekiem, rocznym	
dochodem i oceną wydawania (6 wykresów np. wiek i dochody, wiek i ocena wydawania itd.). In [5]: titleDict = {'fontsize': 20, 'weight':'bold'} In [11]: sns.set_context('paper')	
<pre>sns.relplot(data=data,</pre>	
Annual Income (3) - 09 - 08 - 07 - 08 - 07 - 08 - 08	
40 - 20 - 20 - 30 - 40 Age 50 - 60 TO In [12]: sns.set_context('paper')	
sns.relplot(data=data, x="Age", y="Spending Score (1-100)", aspect=2.5, kind='line') plt.title("Age to Score", fontdict=titleDict) plt.show() Age to Score	
98 - 8 8 - 8 8 - 9 8 9 - 9 8 9 - 9 9 9 9	
20 - 20 - 30 Age 50 70	
<pre>sns.set_context('paper') sns.relplot(data=data,</pre>	
100 - 80 - 100 -	
20 40 60 Annual Income (k\$)	
In [14]: sns.set_context('paper') sns.relplot(data=data,	
70 - 60 - 50 - 90	
30 - 20 - 20 - 40 Annual income (k\$)	
Annual Income (k\$) In [15]: sns.set_context('paper') sns.relplot(data=data,	
Score to Age	
30 - 20 - 40 - 60 80 100	
In [16]: sns.set_context('paper') sns.relplot(data=data,	
Score to Annual Income 140 - 120 - 100 - 300 -	
Au	
Dokonać niezbędnych zmian w bazie danych potrzebnych do rozpoczęcia procesu klasteryzacji (kolumna płeć i ID)	
In [6]: le = preprocessing.LabelEncoder() new_name = le.fit_transform(data["Gender"]) data["Gender"] = new_name data.drop(columns=["CustomerID"], inplace=True) Wygenerować macierz kowariancji i korelacji. In [7]: correlation = data.corr()	
correlation.round(3).style.background_gradient() Out[7]: Gender Age Annual Income (k\$) Spending Score (1-100) Annual Income (k\$) 0.056000 -0.012000 -0.0327000 Spending Score (1-100) -0.058000 -0.012000 0.010000 1.000000 -0.058000 -0.327000 0.010000	
In [8]:	
Dokonać klasteryzacji z użyciem algorytmu k-średnich dla k=5 z uwzględnieniem tylko dwóch kolumn (wybrać je na podstawie wyników	
macierzy kowariancji i korelacji). In [9]: # wybrałem spendingScore i Age ze względu na największy wynik w korelacji i największy w kowariancji claster_without_PCA_data = data.iloc[0:, 1:4].drop(columns=["Annual Income (k\$)"]).values kmeans = KMeans(n_clusters=5, random_state=18) kmeans.fit_transform(claster_without_PCA_data) pass In [10]: plt.scatter(claster_without_PCA_data[0:, 0],claster_without_PCA_data[0:, 1], c=kmeans.labels_, cmap="jet") plt.title("KMeans of 5 in Age and Spending Score (1-100)") plt.title("KMeans of 5 in Age and Spending Score (1-100)")	
plt.title("KMeans of 5 in Age and Spending Score (1-100)") plt.ylabel("Spending Score (1-100)") plt.show() KMeans of 5 in Age and Spending Score (1-100) KMeans of 5 in Age and Spending Score (1-100)	
20 40 40 50 60 70 Age	
In [11]: plt.scatter(kmeans.cluster_centers_[:, 0], kmeans.cluster_centers_[:, 1], s=200, c='yellow', label = 'Centroids') plt.xlabel('Annual Income (k\$)') plt.ylabel('Spending Score (1-100)') plt.show() Centers of clusters O O O O O O O O O O O O O	
001-10-05-05-05-05-05-05-05-05-05-05-05-05-05	
<pre>In [26]: features = ['Age', 'Annual Income (k\$)', 'Spending Score (1-100)'] # Separating out the features x = data.loc[:, features].values # Standardizing the features x = StandardScaler().fit_transform(x) pca = PCA(n_components=2) principalComponents = pca.fit_transform(x) principalComponents = pca.fit_transform(x) principalDf = pd.DataFrame(data = principalComponents) principalDf1 = pd.DataFrame(data = principalComponents)</pre>	
pca.explained_variance_ratiosum() Out[26]: 0.7757454566976748 Nie można ponieważ nie wychodzi poza 80 procent In [13]: pca = PCA(n_components=3) principalComponents = pca.fit_transform(x) principalDf2 = pd.DataFrame(data = principalComponents	
<pre>fig = plt.figure(figsize = (8,8)) ax = fig.add_subplot(1,1,1,projection="3d") ax.set_xlabel('Principal Component 1', fontsize = 15) ax.set_ylabel('Principal Component 2', fontsize = 15) ax.set_ylabel('Principal Component 3', fontsize = 15) ax.set_zlabel('Principal Component 3', fontsize = 15) ax.set_title('2 component PCA', fontsize = 20) targets = ['G', 'A', 'S', 'I', 'H'] colors = ['r', 'g', 'b', 'y', 'orange'] i = 0 for target, color in zip(targets,colors): ax.scatter(principalDf2.loc[km == i]['principal component 1'] , principalDf2.loc[km == i]['principal component 2']</pre>	
<pre>, principalDf2.loc[km == i]['principal component 2'] , principalDf2.loc[km == i]['principal component 3'] , c = color , s = 50) i += 1 ax.legend(targets) ax.grid() 2 component PCA</pre>	
A 5 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1	
Principal Component 1 ² -2 Rinking and the state of the	
Porównać wyniki klasteryzacji z użyciem PCA i bez In [47]: plt.scatter(claster_without_PCA_data[0:, 0],claster_without_PCA_data[0:, 1], c=kmeans.labels_, cmap="jet") plt.title("Claster_without_PCA")	
plt.title("Claster withOUT PCA") plt.axis('off') plt.show() Claster withOUT PCA	
<pre>In [72]: plt.scatter(principalDf[0], principalDf[1], c=kmeans.labels_, cmap='jet', s=14) plt.title("Claster with PCA") plt.axis('off')</pre>	
plt.axis('offf') plt.axis('offf') claster with PCA Claster with PCA	
Klasteryzacja z PCA jest dużo wydajniejsza i dokładna od klasteryzacji bez PCA	
Opisać krótko każdą grupę nadając jej odpowiednią nazwę własną (np. klienci docelowi). Ocenić potencjał grup pod względem przyszłych wyników sprzedaży. Do kogo należy kierować najwięcej informacji marketingowych?	
<pre>final_data = pd.concat([data, pd.DataFrame(data = km, columns=["Group_Predicted"])], axis=1) grouped_final_data = final_data.groupby(["Group_Predicted"]) # grouped_final_data.mean().round()) print(grouped_final_data.get_group(0).mean().round()) print("</pre>	
print("	
Annual Income (k\$) 86.0 Spending Score (1-100) 19.0 Group_Predicted 1.0 dtype: float64	
Gender 0.0 Age 46.0 Annual Income (k\$) 27.0 Spending Score (1-100) 18.0 Group_Predicted 3.0 dtype: float64	
Grupa 0	
Jest to grupa istotna dla nas pomimo dużego wieku średniego, nie jest on aż tak duży bo jedynie 40 lat, a ich zarobki wyglądają obiecująco Grupa 2 > Młodzi, dobrze zarabiający (Grupa Focusowa) Jest to Grupa na której powinniśmy się skupić ze względu na to, że są w stanie dużo wydać oraz w młodym wieku kupuje się więcej nieprzydatnych przedmiotów. Grupa 3 > Starsi, słabo zarabiający (Nieistotna)	
Nie jest to grupa istotna dla nas ze względu na bardzo małe zarobki. Grupa 4 > Młodzi, słabo zarabiający (Nieistotna) Pomimo młodego wieku nie jest to istotna grupa ze względu na bardzo małe zarobki, które nie są dla nas satysfakcjonujące.	
Czy w poszczególnych grupach dominuje któraś z płci? In [95]: for i in range(5): plt.bar(["Female", "Male"], grouped_final_data.get_group(i).groupby(["Gender"]).size()) plt.title("Gender of group " + str(i)) plt.show() Gender of group 0 25	
20 - 15 - 10 - 5 - 6 - 6 - 6 - 6 - 6 - 6 - 6 - 6 - 6	
Gender of group 1 20.0 - 17.5 - 15.0 - 10.0 -	
7.5 - 5.0 - 2.5 - 0.0 Female Male Gender of group 2 20 - Gender of group 2	
15 - 10 - 5 - 5 - Female Male	
Female Male Gender of group 3 12 10 8 6 4	
Female Male Gender of group 4	
25 - 20 - 15 - 10 - 5 - 5 - 6 - 6 - 6 - 6 - 6 - 6 - 6 - 6	
Wszędzie oprócz grupy pierwszej możemy zaobserwować dysproporcję w rodzaju płci na korzyść płci źeńskiej Czy z wstępnej analizy danych wynikają jakieś widoczne zależności np.	
między wiekiem a oceną wydawania? Można zauważyć zależność pomiędzy SpendingScore i Age ze względu na największy wynik w korelacji i największy w kowariancji spośród parametróv	V